

RAG 系统技术手册与星垣科技制度汇编

第一部分 RAG 系统技术手册

§ 01 文档加载与解析

文档加载（document loading）是 RAG 管道的第一道工序，任务是把 PDF、Word、HTML、Markdown 等格式各异的文件统一转换成“纯文本加元数据”的结构。元数据通常包括来源文件名、页码、章节标题和修改时间，后续的引用展示和过滤检索都依赖它们。

PDF 是最难处理的格式。PDF 文件本质上是一串绘图指令，记录的是“在某个坐标画某个字形”，并不保存段落、表格和阅读顺序等语义结构。因此从 PDF 中抽取文字天然是有损的：双栏排版的论文如果按坐标顺序抽取，左右两栏的句子会交错在一起；表格会被拆成一行行互不相关的数字；页眉页脚会混进正文。

另一个隐蔽问题是字体编码。PDF 内部用字形编号而不是字符来记录文字，需要依靠内嵌的映射表才能还原成字符。如果映射表缺失或错误，抽取结果就会变成乱码，而且不会产生任何报错。工程上的做法是在入库前抽样检查解析结果；对于扫描件，则需要先做光学字符识别（OCR）。

加载器的选择取决于文档来源。网页需要去掉导航栏、广告和脚本等噪声，只保留正文；Word 文档要保留标题层级，因为标题是最有价值的元数据之一；表格密集的财报类 PDF，通常要先用版面分析模型识别出表格区域，再把表格转换成 Markdown 或 HTML 表格结构，否则数字与表头之间的对应关系会完全丢失。

§ 02 文本切分

文本切分（chunking）把长文档拆成若干较短的块，每个块单独向量化和检索。之所以要切分，一方面是嵌入模型和大模型都有输入长度上限，另一方面是检索的粒度决定了带回给模型的信息密度。

块的大小需要在两个相互矛盾的目标之间取得平衡。块太大时，一次检索会带回大量与问题无关的内容，真正有用的一两句话被稀释，相似度分数也会被无关内容拉低，同时挤占大模型的上下文窗口。块太小时，一句完整的论述可能被切到两个块里，单独看任何一块都缺少主语或结论，模型无法据此作答。

常见的起点是每块 500 到 1000 个 token，块与块之间保留 10% 到 20% 的重叠，让跨越边界的句子至少完整出现在其中一个块里。递归字符切分器会优先在段落、句子等自然边界处断开，只有当一段话本身超长时，才退而求其次按字符截断。

除了按长度切分，还有按语义切分的做法：先计算相邻句子的向量相似度，在相似度骤降的位置断开，让每个块尽量只讲一个主题。另一种思路是父子块策略：用小块做检索以保证匹配精准，命中后再把它所属的大块交给模型，以保证上下文完整。

§ 03 向量化与嵌入模型

向量化（embedding）用嵌入模型把一段文本映射成一个固定维度的浮点数向量。训练良好的嵌入模型会让语义相近的文本在向量空间中距离也相近，于是“语义是否相关”就被转换成了可以计

算的几何距离。

不同嵌入模型的训练方式差异很大。有的模型只在无标注文本上做对比学习，擅长判断两段文字是否“像”，却不擅长判断一个问题和一段答案是否“配”；有的模型额外使用了大量人工标注的问题与段落配对数据进行训练，专门学习从问题找到答案。前者在问题和文档用词差异大时表现明显较差。

嵌入模型还有最大输入长度，超过上限的部分会被静默截断，不产生任何警告，这是切分参数设置不当时最难发现的数据丢失。选择模型时还要注意语言匹配：中文语料应使用在中文数据上训练过的模型。

常见的向量维度有 384、768 和 1024 维。维度越高，能表达的语义细节越多，存储和计算开销也越大。多数嵌入模型要求对向量做归一化，使其长度为 1，这样余弦相似度与内积完全等价。部分模型还要求在查询文本前加上固定的指令前缀，例如“为这个句子生成表示以用于检索相关文章”，漏加前缀会让短查询的检索效果明显下降。

§ 04 向量检索与近似最近邻

向量检索把用户问题也转换成向量，然后在向量库中找出与之最接近的若干个文档块，距离通常用余弦相似度或内积衡量。它的优势是能识别同义改写，例如“怎么退货”和“退换货流程”虽然用词不同，向量却很接近。

当文档数量达到百万级时，逐一计算距离的开销无法接受，向量库会使用近似最近邻（ANN）索引，例如 HNSW 图索引或 IVF 倒排索引，用少量精度损失换取数量级的速度提升。索引参数决定了召回率与查询延迟之间的取舍。

向量检索有一个结构性弱点：问题通常很短，而文档块很长，两者在文本形式上差异很大。一个十几个字的问句和一段数百字的说明文，即使讲的是同一件事，在向量空间中也未必靠得很近。

向量库的选型要考虑数据规模、是否需要按元数据过滤、是否需要分布式部署。本地实验常用 FAISS 或 Chroma 这类轻量方案；生产环境则多用 Milvus、Qdrant 等独立服务，它们支持水平扩展、持久化存储和元数据过滤。

§ 05 BM25 关键词检索

BM25 是一种经典的关键词检索算法，它根据查询词在文档中出现的次数、该词在整个语料中的稀有程度以及文档长度来打分。一个词出现在越少的文档中，它的区分度就越高，权重也越大。

与向量检索相比，BM25 对字面精确匹配非常可靠。产品型号、订单编号、错误码、人名和专有缩写这类字符串，嵌入模型往往无法准确区分，常常把两个只差一位数字的编号视为几乎相同；而 BM25 按字面逐词比对，能够准确命中。

BM25 的弱点是完全不理解语义：用户换一种说法，只要关键词不重合，它就找不到。处理中文时，它还需要先做分词，分词质量会直接影响检索效果。

BM25 有两个可调参数： k_1 控制词频的饱和速度，一个词在文档中出现第十次带来的加分远小于第一次； b 控制文档长度归一化的强度，防止长文档仅仅因为字数多而占便宜。实践中 k_1 常取 1.2 到 2.0， b 常取 0.75。

§ 06 混合检索与结果融合

混合检索 (hybrid search) 同时运行 BM25 和向量检索，再把两路结果合并成一个排序，兼顾字面精确与语义泛化。难点在于两路分数的量纲不同：BM25 分数没有上界，余弦相似度在 -1 到 1 之间，直接相加没有意义。

倒数排名融合 (Reciprocal Rank Fusion, RRF) 绕开了分数量纲问题，只使用排名：每个文档的融合分数等于它在各路结果中排名的倒数之和，通常还会在排名上加一个常数 60，以平滑头部差距。某个文档只要在任意一路中排得靠前，就能在最终结果中获得较高位置。

当用户查询中同时包含自然语言描述和精确标识符时，混合检索的优势最明显，它也是生产环境中最常见的检索配置之一。

除了 RRF，也可以先把两路分数各自归一化到 0 到 1 之间，再按权重加权求和。这种方式允许手动调节语义与关键词的比重，但权重需要在标注数据上调优，换一个领域往往要重新调。

§ 07 重排

重排 (re-ranking) 是检索之后的第二道精选工序。第一阶段的召回追求“不漏”，会从海量文档中快速捞出几十到上百个候选；第二阶段的重排追求“排准”，用更精细但更慢的模型对这些候选重新打分，只把最相关的几条交给大模型。

重排通常使用交叉编码器 (cross-encoder)。双塔结构会把问题和文档分别编码成向量再比较；交叉编码器则把问题和候选文档拼在一起输入同一个模型，让两边的每个词都能相互关注，因此判断更准确。代价是每个候选都要单独计算一次，无法提前建索引，只能用于少量候选。

重排的效果上限受制于召回：如果正确答案根本没有进入候选集合，重排模型再强也无法把它排上来。

重排模型的输入长度同样有限，候选块过长时会被截断。在延迟敏感的场景中，常见配置是向量检索召回 50 条、重排后保留前 5 条；重排这一步往往占到整条检索链路延迟的一半以上。

§ 08 检索效果评估

评估检索效果需要一组带标准答案的测试问题，即为每个问题标注出哪些文档块是真正相关的。没有标注数据，任何“效果变好了”的判断都只是主观印象。

常用指标包括：命中率 (Hit@k)，即前 k 个结果中是否至少包含一个相关块；召回率 (Recall@k)，即相关块中有多大比例出现在前 k 个结果里；平均倒数排名 (MRR)，即第一个相关块排名的倒数的平均值，用来衡量正确答案是否排得足够靠前。

比较两种检索策略时，测试问题的设计必须独立于策略本身。如果出题人事先知道哪种策略会赢，并有意无意地挑选对它有利的问题，评估结论就失去了意义。

除了检索指标，还需要评估最终生成的答案，例如答案是否忠实于检索到的内容、是否真正回答了问题。检索指标高而答案质量差，说明问题出在生成环节；检索指标低，则应优先优化切分、嵌入和召回。

第二部分 星垣科技内部制度汇编（教学用虚构材料）

§ 09 差旅住宿与报销标准

员工因公出差产生的住宿费用按目的地城市等级实行上限管理：北京、上海、深圳三地每晚上限 680 元，其他省会城市每晚上限 480 元，其余城市每晚上限 360 元。超出上限的部分由员工自行承担，不得通过拆分发票或虚报天数的方式规避。

两名同性别员工同行时原则上合住一间，按单人上限的 1.5 倍执行。出差期间的市内交通按实际发生额报销，每日不超过 120 元；伙食补助按天发放，每天 100 元，无需提供发票。

所有差旅费用须在出差结束后 20 个自然日内通过内部报销系统“鹊桥”提交，逾期提交需要所在事业部总监书面说明原因。财务部每月 5 日和 20 日统一付款。

出差须事先在 OA 系统中提交出差申请并获批准，未经审批产生的差旅费用一律不予报销。因紧急任务确实无法事前申请的，须在出发后 24 小时内补提申请。国际出差的住宿标准另行规定，不适用本条。

§ 10 线上故障值班制度

研发中心实行 7×24 小时轮值制度，每条业务线每周安排一名主值班工程师和一名副值班工程师，交接时间为每周一上午 10 点。值班期间手机须保持畅通，夜间接到告警后应在 15 分钟内响应，30 分钟内给出初步判断。

故障按影响范围分为三级：P1 为核心交易链路不可用或影响全部用户，须立即电话通知业务线负责人，并在 1 小时内拉起故障复盘群；P2 为部分功能异常，须在 4 小时内处理；P3 为非紧急缺陷，排入下一个迭代。若故障涉及其他团队维护的内部系统，应按《内部系统代号一览》找到对应负责团队，并直接呼叫其当周值班人。

值班工程师每完成一周值班可获得 2 天调休额度；夜间实际处理 P1 故障的，每次额外计 0.5 天。调休额度的使用规则见年假与调休制度。

每次 P1 故障结束后 3 个工作日内，主值班工程师须提交故障复盘报告，写明时间线、根因、影响范围和改进项，每个改进项都要指定负责人和完成日期。同一根因在一个季度内重复引发 P1 故障的，相关团队负责人须向技术委员会当面汇报。

§ 11 数据保留与删除制度

公司按数据敏感程度将业务数据分为 L1 至 L4 四级。L4 为用户身份证号、银行卡号等高敏感数据，只能存放在加密隔离区，保留期限不超过业务所需的最短时间，账户注销后 30 天内必须物理删除。L3 为用户行为日志，原始日志保留 180 天，之后只保留脱敏后的汇总结果。

应用运行日志统一接入日志平台，默认保留 90 天；涉及审计的操作日志保留 3 年。任何人需要延长保留期限，须向数据治理委员会提交申请，说明用途和访问范围。

员工离职时，其个人工作目录中的数据由直属上级在 15 个工作日内完成交接确认；逾期未确认的，由信息安全部统一归档后清除。

测试环境禁止使用未脱敏的生产数据。确需使用真实数据排查问题的，须经信息安全部审批，使用完毕后 7 天内删除，并在审批单中登记删除记录。

§ 12 内部系统代号一览

为便于沟通，公司内部系统统一使用代号。“鹊桥”是报销与付款系统，由财务信息化组维护；“青鸾”是统一日志与告警平台，负责收集全公司的应用日志和监控指标，由基础架构部可观测性组维护，其当周值班人可在企业通讯录中搜索“青鸾值班”找到；“玄武”是核心交易数据库集群，由数据库运维组维护。

“司南”是内部配置中心，存放各服务的开关与参数，修改线上配置须经过双人复核；“烛龙”是离线数据仓库与报表平台，由数据平台部维护；“驿站”是内部消息队列服务。新员工入职第一周须完成上述系统的账号开通。

系统代号只在内部文档和内部沟通中使用。对外材料、客户邮件和公开演讲中一律使用正式产品名称，不得出现内部代号。

内部系统的访问权限按最小授权原则分配。申请“玄武”数据库的只读权限须经数据库运维组审批，写权限还须部门总监审批；申请“司南”配置中心的发布权限，须先通过线上变更规范考试。

§ 13 采购申请与审批流程

部门采购办公设备、软件许可和外部服务时，须先在采购系统中提交申请，写明用途、数量、预算和候选供应商。单笔金额在 5000 元以下的由部门负责人审批；5000 元至 5 万元的须增加财务部审核；超过 5 万元的须提交采购委员会评审，并至少比较三家供应商的报价。

采购到货后，申请人须在 7 个工作日内完成验收并上传发票，发票抬头必须为公司全称。软件订阅类采购须在到期前 30 天由申请部门确认是否续费，逾期未确认的默认不再续费。

个人垫付的小额采购不走本流程，而是按费用报销处理，但单笔金额不得超过 1000 元。

所有采购合同须经法务部审核后方可签署。与同一供应商在一个财年内累计交易金额超过 20 万元的，须纳入年度供应商评估，由采购委员会综合考察交付质量、价格和服务响应速度。

§ 14 年假与调休制度

员工入职满一年后享有带薪年假：累计工龄 1 至 10 年的每年 5 天，10 至 20 年的每年 10 天，20 年以上的每年 15 天。公司另外每年赠送 3 天福利假。当年未休完的年假可顺延至次年 3 月 31 日，逾期作废。

调休额度来源于值班和经批准的加班，有效期为获得之日起 6 个月。使用调休须提前 1 个工作日在人事系统中申请，连续使用超过 3 天的须经事业部总监批准。

在核心交易链路的值班周内，主值班工程师不得申请年假或调休；确有紧急情况的，须自行找到同业务线的替班人，并经组长确认。

病假须提供二级以上医院出具的证明，病假期间按国家规定发放工资。婚假 10 天、陪产假 15 天，均须在事件发生后一年内休完，且不可拆分为半天使用。

第三部分 星垣科技产品与运维手册

§ 15 传感器 X200-Pro 产品规格

X200-Pro 是星垣科技第二代工业温湿度传感器，采用 RS485 接口，供电电压 12V 至 24V 直流，工作温度范围为 -20°C 至 60°C ，防护等级 IP65。出厂固件版本为 v3.2，支持通过上位机工具在线升级。

X200-Pro 的整机保修期为 24 个月，自发货日起计算。保修范围覆盖元器件失效与固件缺陷，不覆盖浸水、跌落和私自拆机导致的损坏。保内维修由区域服务中心受理，平均返修周期为 7 个工作日。

X200-Pro 的采样周期默认为 5 秒，可通过寄存器 0x0104 调整为 1 秒至 60 秒。连续工作超过 18 个月建议做一次现场校准，校准偏差超过 $\pm 0.5^{\circ}\text{C}$ 的应申请更换探头。

§ 16 传感器 X210-Pro 产品规格

X210-Pro 是 X200-Pro 的宽温升级型号，接口与安装尺寸完全兼容，供电电压同为 12V 至 24V 直流，但工作温度范围扩展为 -40°C 至 85°C ，防护等级提升至 IP67。出厂固件版本为 v4.1，不可降级至 v3.x。

X210-Pro 的整机保修期为 12 个月。保修期短于上一代的原因是宽温器件在极端环境下的老化速度更快，公司对超出常温区间的使用场景另行提供延保服务，需在购机时一并签订。

X210-Pro 的采样周期默认为 2 秒，寄存器地址与上一代一致。它不支持上一代使用的旧版上位机工具，现场升级须改用 v4 系列工具包，混用会导致固件校验失败。

§ 17 错误码 E5021 与 E5022 排查手册

E5021 表示设备证书已过期。设备证书有效期为 24 个月，过期后设备仍能采集数据但无法上报。处理步骤是在配置中心为该设备重新签发证书，再远程重启一次上报进程，通常 3 分钟内恢复。

E5022 表示证书链不完整，即设备持有的证书本身有效，但中间 CA 证书缺失或版本不匹配。它最常出现在 2026 年 3 月根证书轮换之后仍未更新固件的设备上。处理步骤是先推送完整证书链包，再重启上报进程；只重新签发设备证书不能解决 E5022。

E5021 与 E5022 的现场表现完全相同，都是设备在线但数据断流，因此必须以错误码本身为准，不能凭现象判断。若两者交替出现，应优先按 E5022 处理。

§ 18 工单编号规则与升级流程

线上问题工单的编号格式为 INC-YYYYMMDD-NNNN，其中 INC 表示故障类工单，中间八位是工单创建日期，末四位是当日流水号。变更类工单前缀为 CHG，咨询类为 REQ，三类工单共用同一套流水号池。

以 INC-20260917-0342 为例，它表示 2026 年 9 月 17 日创建的第 342 号故障工单。查询历史工单时必须使用完整编号，只输入流水号会命中其他日期的同号工单。

工单升级规则按响应时限执行：P1 工单 15 分钟内无人认领自动升级至值班组长，P2 工单 2 小时内无进展升级至业务线负责人。升级动作会在工单编号后追加后缀 -E1、-E2，原编号保持不变。

§ 19 接口限流阈值与配额申请

数据上报接口 /v1/ingest 的默认限流阈值为每分钟 600 次请求，单次请求体不超过 256KB。查询接口 /v1/query 的默认阈值为每分钟 3000 次。两个接口的限流按接入密钥独立计算，互不影响。

触发限流时接口返回 HTTP 429，响应头 Retry-After 给出建议的重试等待秒数。客户端应按指数退避重试，连续 5 次 429 之后应暂停上报并告警，避免把限流演变成雪崩。

临时提升配额须提交 CHG 类工单，写明业务背景、预计峰值和持续时间，由平台组评估后生效，单次提升有效期最长 30 天。永久提升配额须走容量评审。

§ 20 差旅交通报销标准

国内出差的城际交通按以下标准报销：单程 800 公里以内优先乘坐高铁二等座，超过 800 公里或无高铁线路的可乘坐经济舱航班。乘坐高铁商务座、一等座或公务舱的差额部分由个人承担，总监及以上职级不受此限。

出差期间的市内交通费实报实销，每日上限 80 元，含网约车、出租车、地铁和公交。机场与车站往返的单次长途接驳不计入每日上限，但须单独提供行程单。

自驾出差按实际里程报销油费与过路费，里程单价为每公里 1.2 元，须提交出发地与目的地的导航截图作为里程凭证。市内通勤、加班打车和团建用车不属于差旅交通，不走本标准。

§ 21 外包人员账号与门禁管理

外包人员入场前须由需求方部门提交入场申请，注明服务内容、驻场周期和接口人。账号由信息安全部统一开立，有效期为 90 天，到期自动停用；需要延长的须在到期前 5 个工作日重新提交申请，单次延长不超过 90 天。

外包账号默认只授予所属项目的代码仓库读权限和测试环境访问权限。申请生产环境任何权限均须双人审批，即需求方部门负责人与信息安全部各审批一次，且必须注明具体到期日，不接受长期有效的申请。

外包人员的门禁卡与账号绑定同一有效期，离场当日须归还门禁卡并由接口人确认账号已停用。连续 30 天无登录记录的外包账号会被自动冻结，解冻须重新走审批。

§ 22 值班补贴发放标准

值班补贴按班次类型发放：工作日夜班每次 200 元，周末白班每次 300 元，法定节假日每次 400 元。补贴随次月工资发放，不可折算为调休，也不可和加班费重复计算。

补贴的计算依据是值班系统中的实际排班记录。临时替班的补贴归实际值班人，替班须在值班系统中完成交接登记，仅口头交接不予认定。一个自然月内同一人的值班补贴累计上限为 3000 元。

主值班工程师在值班周内被叫醒处理故障且单次处理超过 1 小时的，可额外申请一次性故障处理补贴 150 元，每周最多申请两次，须附对应的工单编号。

§ 23 检索质量监控原则

检索质量不能只依赖上线前的一次性评测，因为线上的提问分布会随着业务变化而漂移，而评测集是静止的。一套可持续的做法是定期抽取线上真实提问，重新标注并补充进评测集，让评测集

跟着业务一起演进。

监控指标应当区分“找不到”和“排不准”两类问题。找不到意味着正确内容压根没有进入候选集合，通常源于切分方式不当或索引覆盖不全；排不准意味着正确内容进了候选但没有排到前面，这才是排序环节该负责的部分。两者的修复手段完全不同，混在一起看会导致优化方向错误。

任何一路检索都可能在不报错的情况下失效，所以多路融合的系统必须分路观测，而不是只看融合后的最终指标。一旦某一路长期没有贡献，就应当视为故障而不是冗余。

§ 24 客户投诉分级与响应时限

客户投诉按影响面分为三级。一级投诉指影响客户核心生产流程或涉及数据安全，须在 15 分钟内响应并同步至事业部负责人。二级投诉指功能受损但有替代方案，须在 2 小时内响应。三级投诉指体验问题或咨询类诉求，须在 1 个工作日内响应。

响应不等于解决。响应指已与客户取得联系并告知处理计划，解决指客户确认问题不再出现。两个时间点都要记录，考核时分别统计，避免出现“秒回但久拖不决”的情况。

同一客户在一个月內重复提出同类投诉两次以上的，须升级为专项跟进，由客户成功团队联合研发复盘根因，并向客户提交书面改进说明。